

Lista de Exercícios #5 – Redes Neurais - João Comini Cesar de Andrade

Questão 01. Sobre os principais conceitos de redes neurais, responda:

1. Redes neurais artificiais são frequentemente comparadas a modelos de "caixa-preta".

Explique o que isso significa no contexto de aprendizado de máquina e qual é a principal desvantagem dessa característica.

R: O efeito "caixa-preta" refere-se ao fato de que a relação entre os dados de entrada e a saída gerada não é clara, tornando muito difícil interpretar como a rede chegou a um determinado resultado. A principal desvantagem dessa característica é a falta de transparência, o que exige a aplicação de métodos adicionais de extração de conhecimento ou ajuste de parâmetros para justificar o comportamento do modelo.

2. O que é um neurônio artificial e como ele se inspira no neurônio biológico? Descreva os principais componentes de um neurônio artificial e explique a função de cada um deles.

R: O neurônio artificial é a unidade fundamental de processamento de uma rede neural artificial, baseada estruturalmente em um neurônio biológico simplificado. Seus principais componentes são:

- Entradas: terminais que recebem valores numéricos simulando estímulos.
- Pesos: associados às conexões, ponderam os valores das entradas, podendo ter um efeito excitatório ou inibitório sobre o sinal.
- Soma (Corpo): componente matemático que multiplica as entradas pelos pesos e realiza a soma total de todos esses valores.
- Função de Ativação: função matemática aplicada ao resultado da soma ponderada para calcular o que o neurônio fará com a informação e, por fim, produzir a Saída.

3. Faça um paralelo entre os principais componentes de um neurônio biológico e os componentes de um neurônio artificial.

R: O paralelo entre os componentes dá-se da seguinte forma

- Os **Dendritos** biológicos equivalem às **Entradas**, pois ambos são responsáveis por receber os estímulos.
- As **Sinapses** equivalem aos **Pesos**, funcionando como válvulas que controlam e ponderam a força do fluxo de informação repassado.
- O **Corpo Celular** equivale à operação de **Soma**, pois combina as informações e as processa.

- O **Axônio** equivale à **Saída** (após a Função de Ativação), sendo a via que transporta o sinal processado para a próxima etapa.
4. Explique o conceito de função de ativação em redes neurais. Por que ela é necessária? Descreva pelo menos três tipos diferentes de funções de ativação.
- R: A função de ativação é uma operação matemática aplicada sobre a soma ponderada das entradas que tem o objetivo de controlar qual será a resposta do neurônio. Ela é necessária essencialmente para adicionar não-linearidade à rede, sem a qual múltiplas camadas seriam equivalentes matematicamente a apenas uma única camada. Três exemplos de funções são:
- **Limiar (Step)**: funciona como um interruptor; define um valor de corte onde o resultado só retorna 1 ou 0.
 - **Sigmoide**: aproximação contínua e diferenciável que gera uma saída sempre entre 0 e 1, bastante útil na camada de saída para classificação binária.
 - **ReLU (Ativação Linear Retificada)**: retorna o próprio valor da entrada se ele for positivo ($\max\{0, x\}$), e 0 caso contrário; é amplamente utilizada em redes profundas atualmente por causa da simplicidade de sua derivada.
5. O modelo original do Perceptron enfrentou um forte declínio na década de 1970, em um período que ficou conhecido como o "inverno da IA". Qual foi a principal limitação matemática apontada na época que causou esse declínio?
- R: O declínio ocorreu depois que Minsky e Papert (1969) demonstraram matematicamente que o modelo do Perceptron de camada única só era capaz de aprender e separar classes de problemas linearmente separáveis. Como o algoritmo consegue traçar apenas uma linha reta (ou hiperplano), a arquitetura falhava para problemas muito simples não lineares, como a função lógica XOR.
6. Para superar as limitações do Perceptron de camada única, consolidou-se a arquitetura Multilayer Perceptron (MLP). Explique como a adição de camadas intermediárias (ocultas) ajuda a resolver problemas mais complexos.
- R: Na arquitetura MLP, a complexidade do processamento vai aumentando conforme as camadas avançam. A primeira camada aprende a gerar hiperplanos que separam as entradas de forma reta; a segunda camada combina vários hiperplanos anteriores formando superfícies convexas; as camadas subsequentes continuam combinando essas superfícies convexas formando, por fim, regiões de separação de formatos totalmente arbitrários e complexos. Assim, a combinação conjunta dos neurônios consegue quebrar a barreira da separabilidade estritamente linear.
7. Qual é a principal justificativa teórica para aplicarmos funções de ativação não lineares (como a função sigmoide) aos neurônios em uma rede do tipo Multilayer Perceptron (MLP)?
- R: A principal justificativa é que uma rede multicamadas composta apenas por funções de ativação estritamente lineares sofre um colapso em suas equações e é, de forma teórica e matemática, equivalente a uma rede contendo apenas uma única camada. Por isso, inserir

funções não lineares é mandatório para garantir que a rede seja capaz de construir as representações complexas exigidas pela união e acúmulo de camadas ocultas.

8. O treinamento da maioria das redes neurais profundas depende do algoritmo de backpropagation (retropropagação). Descreva as duas fases principais desse algoritmo.

R: O backpropagation é constituído pelas seguintes fases baseadas em correção de erros:

- **Fase de Propagação (Forward pass):** os dados entram na rede e o processamento é feito para frente. Cada neurônio computa sua saída e a repassa para a próxima camada, até que a rede finalmente emita a resposta de predição.
- **Fase de Retropropagação (Backward pass):** o erro é medido e, em seguida, ele é repassado para trás através da rede, da camada de saída em direção à primeira camada intermediária. Enquanto o erro viaja retroativamente, os pesos de todas as conexões vão sendo reajustados para corrigir a discrepância.

9. O algoritmo de retropropagação se apoia no método de gradiente descendente para atualizar os pesos da rede. Qual é a intuição por trás do uso de derivadas nesse método de otimização?

R: O gradiente descendente usa derivadas porque elas agem como uma "bússola" sobre o erro. A derivada aponta "a direção e a intensidade" indicando o que ocorre com o erro final caso mudemos um peso. Se a derivada do erro em relação a um peso for positiva, sabemos que o peso aumenta o erro (então devemos reduzi-lo). Se for negativa, o peso contribui para reduzir o erro (então devemos aumentá-lo). A busca é por derivadas próximas de zero, onde o erro atingirá um ponto mínimo e estável.

10. A taxa de aprendizado (learning rate) é um hiperparâmetro fundamental no treinamento de redes neurais pelo algoritmo de backpropagation. O que essa taxa define no ajuste de pesos e quais os riscos de configurá-la com valores muito altos ou muito baixos?

R: A taxa de aprendizado é o valor numérico que define o "tamanho do passo" da magnitude do ajuste feito no peso ao longo do treinamento, modulando a velocidade de convergência.

- **Riscos com valores muito baixos:** provocam apenas pequenas variações nos pesos, fazendo com que a convergência da rede seja extremamente lenta, correndo forte risco do algoritmo estagnar e ficar travado em mínimos locais de erro.
- **Riscos com valores muito altos:** causam oscilações enormes nos parâmetros e comportamento instável, o que pode fazer com que o gradiente simplesmente pule e "erre" o ponto do mínimo global da função.

Questão 02. Quais são os principais desafios éticos e sociais relacionados ao uso de modelos baseados em redes neurais em aplicações do mundo real? Pesquise e discuta pelo menos três

aspectos (um parágrafo para cada). Inclua as fontes utilizadas para construir a sua resposta.

Viés Algorítmico e Discriminação: O desempenho de modelos de redes neurais depende intimamente da qualidade dos dados em que são treinados. Caso essas bases de treinamento reflitam falhas humanas, preconceitos raciais ou desigualdades sistêmicas do passado, a rede neural aprenderá e reproduzirá isso em escala. Um desafio ético formidável se apresenta ao usarmos IA no campo de aprovação de créditos, avaliação de sentenças ou em contratações de RH, onde o sistema pode tomar decisões abertamente preconceituosas. (Fonte: O'Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*).

Transparência e o Dilema da "Caixa-Preta": Como vimos nos fundamentos das redes neurais profundas, a sua arquitetura baseada em milhões (e às vezes bilhões) de pesos e conexões impede que nós compreendamos o "por quê" uma decisão foi tomada pelo modelo. Esse fenômeno desafia o direito que as pessoas têm de explicações quando uma máquina nega sua inscrição médica, cancela seu voo ou decreta prisões. Sem transparência, falhas letais tornam-se impossíveis de serem auditadas. (Fonte: Mittelstadt, B. D., et al. (2016). "The ethics of algorithms: Mapping the debate". *Big Data & Society*).

Privacidade e Coleta Massiva de Dados: Para atingirem bons graus de confiança, as redes neurais dependem de massas enormes de dados, comumente referidas como *Big Data*. Isso cria incentivos não éticos para que grandes corporações capturem os dados pessoais e metadados dos indivíduos através da internet, rotineiramente sem transparência sobre consentimento pleno. O uso destas informações para treinar sistemas vigilantes (ex: o avanço impiedoso de reconhecimento facial) pode ferir direitos fundamentais e propiciar controle social invasivo. (Fonte: Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*).