

ConsultaAI — Planejamento de Capacidade em Nuvem

Definição e Otimização de SLAs para Infraestrutura Cloud | Budget: R\$ 20.000,00/mês

1. Empresa — ConsultaAI Telemedicina

A ConsultaAI é uma startup brasileira de telemedicina, com sede em Belo Horizonte-MG, que conecta pacientes a médicos via consultas por vídeo, chat e telemonitoramento de sinais vitais, operando 24/7. Com 300 clínicas parceiras e 80.000 usuários ativos mensais, projeta crescimento de 40% ao ano. A migração para a nuvem é motivada pela necessidade de elasticidade, resiliência, conformidade com LGPD/ANS e redução de capex.

Perfil de carga: 10 milhões de requisições/mês, picos de até 60 req/s nos horários de maior demanda (8h–12h e 17h–20h). O caráter crítico do serviço de saúde exige alta disponibilidade e indisponibilidade representa risco direto ao paciente.

2. SLAs Recomendados e Justificativas

A estratégia adotou leve priorização da disponibilidade ($w_a=0,40$) frente ao tempo de resposta e taxa de processamento ($w_r=w_x=0,30$), refletindo o perfil crítico de saúde digital. A função de utilidade da ferramenta SOLVER_MAD é:

$$U = w_r \cdot [2 \cdot e^{(-SLAr)} / (1 + e^{(-SLAr)})] + w_x \cdot [1 - e^{(-0,1 \cdot SLAx)}] + w_a \cdot [10 \cdot SLAa - 9]$$

Parâmetro	Valor SLA	Tier de Custo	Justificativa
Tempo Resposta (SLAr)	2 segundos	R\$0,027/1k req	Consultas médicas toleram até 2s; abaixo disso o custo dobra sem ganho perceptível.
Taxa Processamento (SLAx)	60 req/s	R\$0,015/1k req	Pico estimado de 50–60 conexões simultâneas; margem de 20% para estabilidade.
Disponibilidade (SLAa)	99,9%	Premium +R\$0,69/1k	Serviço de saúde crítico — máx. 8,7h de indisponibilidade/ano tolerável.

Com $SLAr=2s$, $SLAx=60$ req/s e $SLAa=99,9\%$, a utilidade resultante é $U=0,7668$ — 9,5% acima do limiar mínimo de 0,70 definido para serviços de saúde digital.

3. Estimativa de Custos de Mercado

Tarifas baseadas em tabelas públicas de AWS/GCP/Azure para a região sa-east-1 (Brasil), referência 2025. O custo total de R\$18.607/mês representa 93% do orçamento, mantendo reserva técnica de ~R\$1.393 (7%) para variações de tráfego.

Item de Custo	Tarifa	Volume Mensal	Custo/Mês (R\$)
Compute -> SLAr=2s	R\$0,000027/req	10.000.000	R\$ 2.707,00
Throughput -> SLAx=60 req/s	R\$0,0015/req	10.000.000	R\$ 9.000,00
Disponibilidade = 99,9%	R\$0,00069/req	10.000.000	R\$ 6.900,00
TOTAL / SALDO	—	Budget: R\$20.000	R\$18.607 ✓

4. Simulações e Análise Comparativa

Foram executadas quatro diferentes situações de simulação na ferramenta SOLVER_MAD, variando os parâmetros de SLA e os pesos da função utilidade. A tabela abaixo compara os cenários com pesos equalizados ($w_r=w_x=w_a=1/3$) para comparação justa. (* Custo em unidade normalizada da planilha; limite orçamentário $\approx 2,0$.)

Cenário	SLA r	SLA x	SLAa	Utilid ade	Custo *	Decisão
Base (planilha)	1 s	50	99,0%	0,8104	1,3311	Referência
Prio. Disponibilidade	3 s	30	99,9%	0,7563	0,5039	Descartado
Prio. Tempo de Resposta	1 s	40	99,0%	0,7394	1,2311	Descartado
Prio. Taxa de Processamento	3 s	90	90,0%	0,5237	0,9996	Descartado
Balanceado Otimizado	1 s	100	99,9%	0,8426	1,8401	Custo alto
★ RECOMENDADO	2 s	60	99,9%	0,7668	0,9750	Escolhido ✓

Simulação 1: Disponibilidade: $w_a=0,50$ melhora $SLA_a=99,9\%$ mas reduz utilidade global ao elevar SLA_r para compensar custo. Adequado a serviços insensíveis a latência.

Simulação 2: Tempo de Resposta: $SLA_r=1s$ eleva custo para $C=1,23$ sem ganho proporcional e a função utilidade satura rapidamente abaixo de 2s.

Simulação 3: Taxa de Processamento: $SLA_x=90$ req/s gera custo elevado com retorno marginal. Para o perfil atual da ConsultaAI, throughput acima de 60 req/s é desnecessário.

Simulação 4: Balanceado Otimizado: máxima utilidade ($U=0,8426$) com $SLA_r=1s+SLA_x=100+SLA_a=99,9\%$, mas custo $C=1,84$ esgota quase todo o orçamento sem margem de segurança.

5. Conclusão

O cenário recomendado tem as seguintes medidas, $SLA_r=2s$, $SLA_x=60$ req/s, $SLA_a=99,9\%$. Este cenário entrega a melhor relação custo-utilidade: $U=0,7668$ com custo normalizado $C=0,9750$, redução de 26,7% em relação à base da planilha com perda de apenas 5,4% de utilidade. O custo mensal estimado de R\$18.607,00 fica dentro do budget de R\$20.000,00, com reserva técnica de 7%. A ênfase em disponibilidade (99,9%) justifica-se pelo risco à saúde em caso de indisponibilidade. Recomenda-se revisão semestral dos SLAs, escalando SLA_x para 80 req/s quando o volume superar 15 milhões de requisições/mês.